

DES4069 — Regressão por Regional de Saúde — SRAG PR 2026

Mesma metodologia da análise nacional por UF, restrita ao Paraná e agregada por Regional de Saúde

Grupo — DES4069

30/08/2026

Contents

1	Por que não dá para “filtrar” o Paraná na análise por UF	2
2	Mapa município → Regional de Saúde do PR	2
3	Importação do banco bruto — via API dados.gov.br, filtrado para o PR	3
4	Atribuição da Regional de Saúde a cada caso	4
5	Idade corrigida (converte dias/meses para anos em vez de descartar)	5
6	Funções auxiliares de proporção	5
7	Agregação: variáveis principais (n_casos, idade, desfechos)	6
8	Agregação de todas as proporções (fatores de risco, vacina, UTI)	6
9	Conferência	7
10	Passo 1 — Correlação de cada candidata com a resposta	8
11	Passo 2 — Modelo preliminar com as 5 maiores correlações entre as candidatas clinicamente diretas (1ª rodada)	9
12	Passo 3 — Diagnóstico de multicolinearidade (VIF e correlação entre regressores)	11
13	Passo 4 — Reespecificação: removendo a redundância	13
14	Passo 5 — Triagem das comorbidades adicionais (2ª rodada)	13
15	Passo 6 — a nova variável torna alguma do modelo intermediário desnecessária?	15
15.1	Resumo do processo de seleção	16

16 Ajuste e Diagnóstico do Modelo Final	17
16.1 Comparação com o modelo reduzido (teste F parcial da última variável adicionada)	18
16.2 Gráficos de diagnóstico padrão dos resíduos	18
16.3 Resíduos studentizados internos e R-student	19
16.4 Resíduos vs. cada regressor	20
16.5 Estatística PRESS	21
16.6 Alavancagem e Distância de Cook	21

17 Equação do Modelo Final	23
-----------------------------------	-----------

18 Comparação com a análise nacional (UF, 2026) e com 2024	23
---	-----------

Réplica da metodologia usada em `DES4069_Regressao_2026.Rmd` (nacional, por UF), agora restrita ao **Paraná** e agregada por **Regional de Saúde** em vez de por UF. A pergunta motivadora é diferente da réplica nacional: ali comparávamos 2024 x 2026 no mesmo nível (UF); aqui trocamos o nível de agregação — dentro de um único estado, o padrão observado entre UFs se repete entre regionais? Mesmo aviso da versão anterior: texto marcado `[PREENCHER]` é para escrever depois de rodar, olhando os números que o código produziu.

1 Por que não dá para “filtrar” o Paraná na análise por UF

A análise nacional agrega por UF (uma linha por estado). Filtrar essa base para `SG_UF_NOT == "PR"` deixaria **uma única linha** — não há como ajustar regressão nenhuma com $n = 1$. Para analisar só o PR é preciso trocar a unidade de agregação para algo que exista *dentro* do estado e mantenha observações razoavelmente independentes entre si (mesmo argumento de sempre — pacientes da mesma região compartilham rede hospitalar e perfil socioeconômico). A Regional de Saúde (RS) da SESA-PR cumpre esse papel: o PR tem 22 regionais, dando $n \approx 22$ — ordem de grandeza parecida com o $n = 27$ da análise por UF.

2 Mapa município → Regional de Saúde do PR

Fonte do mapeamento (arquivo `municipios_pr_regional_saude.csv`, carregado abaixo): tabela oficial da SESA-PR com os 399 municípios e código IBGE de 6 dígitos (mesmo formato do campo `CO_MUN_RES` do SIVEP-Gripe), cruzada com as páginas oficiais de cada uma das 22 Regionais em `saude.pr.gov.br` para conferir a contagem de municípios por regional. Um município (Alto Paraíso) não apareceu em nenhuma das 22 páginas oficiais consultadas — foi colocado na 11ª RS (Campo Mourão) por posição na tabela-fonte, **não por confirmação textual explícita**; ver coluna `fonte_confivel` no CSV. [Não verificado] confira esse caso se Alto Paraíso aparecer entre os casos analisados.

```
mapa_regionais <- readr::read_delim(
  "municipios_pr_regional_saude.csv", delim = ";",
  locale = readr::locale(encoding = "UTF-8"),
  col_types = readr::cols(.default = "c"),
  progress = FALSE
)
nrow(mapa_regionais) # deve ser 399
```

```
## [1] 399
```

```
table(mapa_regionais$regional_nome)
```

```
##
##          10ª RS - Cascavel          11ª RS - Campo Mourão
##                      25                      26
##          12ª RS - Umuarama          13ª RS - Cianorte
##                      20                      11
##          14ª RS - Paranavaí          15ª RS - Maringá
##                      28                      30
##          16ª RS - Apucarana          17ª RS - Londrina
##                      17                      21
##          18ª RS - Cornélio Procopio  19ª RS - Jacarezinho
##                      21                      22
##          1ª RS - Paranaguá          20ª RS - Toledo
##                      7                      18
##          21ª RS - Telêmaco Borba     22ª RS - Ivaiporã
##                      7                      16
## 2ª RS - Curitiba (Metropolitana)     3ª RS - Ponta Grossa
##                      29                      12
##          4ª RS - Irati              5ª RS - Guarapuava
##                      9                      20
##          6ª RS - União da Vitória    7ª RS - Pato Branco
##                      9                      15
##          8ª RS - Francisco Beltrão    9ª RS - Foz do Iguaçu
##                      27                      9
```

3 Importação do banco bruto — via API dados.gov.br, filtrado para o PR

Mesma fonte e mesmas convenções da réplica nacional de 2026 (separador ;, encoding latin1, tudo lido como texto). Diferença: filtra só SG_UF_NOT == "PR" logo após o download.

```
rm(list = setdiff(ls(all = TRUE), "mapa_regionais")) # preserva o mapa já carregado

ID_CONJUNTO_SRAG <- "39a4995f-4a6e-440f-8c8f-b00c81fae0d0" # SRAG 2019 a 2026
ANO_ANALISE_REG <- 2026

obter_token_dados_gov <- function() {
  token <- Sys.getenv("DADOS_GOV_TOKEN")
  if (token == "") {
    stop(
      "DADOS_GOV_TOKEN não configurado. Adicione a linha ",
      "DADOS_GOV_TOKEN=seu_token em ~/.Renviron e rode readRenviron('~/.Renviron')."
    )
  }
  token
}

localizar_recurso_ano <- function(ano, formato = "CSV") {
  token <- obter_token_dados_gov()
  resp <- httr::GET(
```

```

paste0("https://dados.gov.br/dados/api/publico/conjuntos-dados/", ID_CONJUNTO_SRAG),
  httr::add_headers(`chave-api-dados-abertos` = token)
)
if (httr::status_code(resp) != 200) {
  stop("Falha ao consultar a API (status ", httr::status_code(resp), ").")
}
recursos <- httr::content(resp, as = "parsed")$recursos
link <- NULL
for (r in recursos) {
  formato_ok <- !is.null(r$formato) && toupper(r$formato) == toupper(formato)
  titulo_ok <- !is.null(r$titulo) && grepl(as.character(ano), r$titulo)
  if (formato_ok && titulo_ok) link <- r$link
}
if (is.null(link)) stop("Recurso ", formato, " de ", ano, " não encontrado na API.")
link

diretorio_cache <- "cache_dados_regressao"
if (!dir.exists(diretorio_cache)) dir.create(diretorio_cache)
caminho_bruto <- file.path(diretorio_cache, paste0("SRAG_API_", ANO_ANALISE_REG, ".csv"))

if (!file.exists(caminho_bruto)) {
  link <- localizar_recurso_ano(ANO_ANALISE_REG, "CSV")
  message("Baixando via API dados.gov.br: ", link)
  download.file(link, destfile = caminho_bruto, mode = "wb")
} else {
  message("Usando arquivo em cache: ", caminho_bruto)
}

dados_brutos <- readr::read_delim(
  caminho_bruto, delim = ";",
  locale = readr::locale(encoding = "latin1"),
  col_types = readr::cols(.default = "c"),
  progress = FALSE
)

dados_brutos <- dados_brutos[dados_brutos$SG_UF_NOT == "PR", ]
nrow(dados_brutos) # total de casos do PR em 2026 na base

```

```
## [1] 18944
```

4 Atribuição da Regional de Saúde a cada caso

Junta pelo código IBGE de residência (CO_MUN_RES). Casos cujo CO_MUN_RES não bate com nenhum município do mapa são **sinalizados explicitamente**, não descartados em silêncio — mesmo cuidado adotado no dashboard da 15ª RS com código de município ausente no shapefile.

```

dados_brutos$regional_num <- mapa_regionais$regional_num[
  match(dados_brutos$CO_MUN_RES, mapa_regionais$codigo_ibge_6)
]
dados_brutos$regional_nome <- mapa_regionais$regional_nome[

```

```

  match(dados_brutos$CO_MUN_RES, mapa_regionais$codigo_ibge_6)
]

n_sem_regional <- sum(is.na(dados_brutos$regional_num))
if (n_sem_regional > 0) {
  codigos_sem_match <- sort(unique(dados_brutos$CO_MUN_RES[is.na(dados_brutos$regional_num)]))
  message(sprintf(
    "%d caso(s) com CO_MUN_RES sem correspondência no mapa de regionais - EXCLUÍDOS da agregação. Códigos: %s",
    n_sem_regional, paste(codigos_sem_match, collapse = ", ")
  ))
} else {
  message("Todos os casos do PR foram atribuídos a uma Regional de Saúde.")
}

dados_brutos <- dados_brutos[!is.na(dados_brutos$regional_num), ]
nrow(dados_brutos) # casos após excluir os sem regional identificada

```

```
## [1] 18723
```

5 Idade corrigida (converte dias/meses para anos em vez de descartar)

Mesma correção das versões anteriores.

```

tp_idade_num <- as.numeric(dados_brutos$TP_IDADE)
nu_idade_n_num <- as.numeric(dados_brutos$NU_IDADE_N)

dados_brutos$idade_anos_corrigida <- ifelse(
  tp_idade_num == 1, nu_idade_n_num / 365.25, # dias -> anos
  ifelse(tp_idade_num == 2, nu_idade_n_num / 12, # meses -> anos
    nu_idade_n_num) # já em anos (TP_IDADE == 3)
)

mean(nu_idade_n_num[tp_idade_num == 3], na.rm = TRUE)

```

```
## [1] 41.10791
```

```
mean(dados_brutos$idade_anos_corrigida, na.rm = TRUE)
```

```
## [1] 33.02697
```

6 Funções auxiliares de proporção

```

prop_sim <- function(x, validos = c("1", "2")) {
  x <- as.character(x)
  denom <- sum(x %in% validos, na.rm = TRUE)
  if (denom == 0) return(NA)
}

```

```

    sum(x == "1", na.rm = TRUE) / denom
  }

regionais_ids <- sort(unique(dados_brutos$regional_num))
length(regionais_ids) # quantas regionais de fato têm caso de SRAG na base

```

```
## [1] 22
```

7 Agregação: variáveis principais (n_casos, idade, desfechos)

Mesma variável resposta das versões anteriores — taxa_letalidade — agora uma linha por Regional de Saúde do PR em vez de uma linha por UF.

```

nome_regional <- function(r) unique(dados_brutos$regional_nome[dados_brutos$regional_num == r])

agregado <- data.frame(regional_num = regionais_ids)
agregado$regional_nome <- sapply(agregado$regional_num, nome_regional)
agregado$n_casos <- sapply(regionais_ids, function(r) sum(dados_brutos$regional_num == r))
agregado$idade_media <- sapply(regionais_ids, function(r)
  mean(dados_brutos$idade_anos_corrigida[dados_brutos$regional_num == r], na.rm = TRUE))
agregado$obitos <- sapply(regionais_ids, function(r)
  sum(dados_brutos$EVOLUCAO[dados_brutos$regional_num == r] == "2", na.rm = TRUE))
agregado$desfecho_conhecido <- sapply(regionais_ids, function(r)
  sum(dados_brutos$EVOLUCAO[dados_brutos$regional_num == r] %in% c("1", "2", "3"), na.rm = TRUE))
agregado$taxa_letalidade <- agregado$obitos / agregado$desfecho_conhecido

```

8 Agregação de todas as proporções (fatores de risco, vacina, UTI)

Mesmas 16 variáveis das versões anteriores (nacional 2024 e 2026), mesmo tratamento especial de prop_suport_ven e mesma exclusão de PUERPERA.

```

mapa_variaveis <- c(
  CARDIOPATI = "prop_cardiopatia", DIABETES = "prop_diabetes",
  OBESIDADE = "prop_obesidade", VACINA = "prop_vacina_gripe",
  VACINA_COV = "prop_vacina_covid", UTI = "prop_uti",
  ASMA = "prop_asma", RENAL = "prop_renal",
  IMUNODEPRE = "prop_imunodepre", NEUROLOGIC = "prop_neurologic",
  PNEUMOPATI = "prop_pneumopati", TABAG = "prop_tabag",
  HEPATICA = "prop_hepatica", HEMATOLOGI = "prop_hematologi",
  SIND_DOWN = "prop_sind_down"
)

for (campo in names(mapa_variaveis)) {
  nome_col <- mapa_variaveis[[campo]]
  agregado[[nome_col]] <- sapply(regionais_ids, function(r)
    prop_sim(dados_brutos[[campo]][dados_brutos$regional_num == r])
  )
}

agregado$prop_suport_ven <- sapply(regionais_ids, function(r) {

```

```

x <- as.character(dados_brutos$SUPPORT_VEN[dados_brutos$regional_num == r])
denom <- sum(x %in% c("1", "2", "3"), na.rm = TRUE)
if (denom == 0) return(NA)
sum(x %in% c("1", "2"), na.rm = TRUE) / denom
})

sum(!is.na(dados_brutos$TABAG))

```

```
## [1] 0
```

9 Conferência

Regionais menores (poucos municípios, ex.: 21ª RS Telêmaco Borba) tendem a ter `n_casos` bem menor que as grandes (ex.: 15ª RS Maringá, 2ª RS Curitiba) — o que deixa a proporção de comorbidades mais instável nelas. [PREENCHER] observe abaixo se alguma regional tem `n_casos` baixo o bastante para pesar essa leitura.

```
nrow(agregado) # deve ser <= 22 (só regionais com caso na base)
```

```
## [1] 22
```

```
colSums(is.na(agregado))
```

```
##      regional_num      regional_nome      n_casos      idade_media
##           0           0           0           0
##      obitos desfecho_conhecido      taxa_letalidade      prop_cardiopatia
##           0           0           0           0
##      prop_diabetes      prop_obesidade      prop_vacina_gripe      prop_vacina_covid
##           0           0           0           0
##      prop_uti           prop_asma           prop_renal      prop_imunodepre
##           0           0           0           0
##      prop_neurológic      prop_pneumopati      prop_tabag      prop_hepatica
##           0           0           22           0
##      prop_hematologi      prop_sind_down      prop_suport_ven
##           0           0           0
```

```
agregado[order(agregado$n_casos), c("regional_num", "regional_nome", "n_casos", "taxa_letalidade")]
```

```
##      regional_num      regional_nome      n_casos      taxa_letalidade
## 6           14      14ª RS - Paranavaí           63      0.111111111
## 15          22      22ª RS - Ivaiporã           106      0.041666667
## 5           13      13ª RS - Cianorte           113      0.123809524
## 19           6      6ª RS - União da Vitória           157      0.077464789
## 4           12      12ª RS - Umuarama           215      0.088541667
## 14          21      21ª RS - Telêmaco Borba           223      0.010471204
## 10          18      18ª RS - Cornélio Procópio           225      0.022471910
## 3           11      11ª RS - Campo Mourão           284      0.023076923
## 1            1      1ª RS - Paranaguá           293      0.054263566
## 8           16      16ª RS - Apucarana           318      0.016000000
## 11          19      19ª RS - Jacarezinho           319      0.056179775
```

## 18	5	5ª RS - Guarapuava	325	0.041509434
## 20	7	7ª RS - Pato Branco	353	0.013201320
## 21	8	8ª RS - Francisco Beltrão	493	0.007142857
## 17	4	4ª RS - Irati	641	0.025728988
## 22	9	9ª RS - Foz do Iguaçu	1056	0.112953368
## 16	3	3ª RS - Ponta Grossa	1206	0.039062500
## 7	15	15ª RS - Maringá	1318	0.090246126
## 2	10	10ª RS - Cascavel	1523	0.064028777
## 13	20	20ª RS - Toledo	1821	0.040024257
## 9	17	17ª RS - Londrina	2237	0.046410891
## 12	2	2ª RS - Curitiba (Metropolitana)	5434	0.059040590

10 Passo 1 — Correlação de cada candidata com a resposta

```

candidatas <- c("idade_media", "prop_cardiopatias", "prop_diabetes", "prop_obesidade",
               "prop_vacina_gripe", "prop_vacina_covid", "prop_uti", "prop_asma",
               "prop_renal", "prop_imunodepre", "prop_neurológico", "prop_pneumopatia",
               "prop_hepática", "prop_hematológico", "prop_sind_down",
               "prop_suporte_ven")
# remove candidatas sem variação/dados suficientes
candidatas <- candidatas[sapply(candidatas, function(v) sum(!is.na(agregado[[v]])) >= 10)]

cor_y <- sapply(candidatas, function(v) cor(agregado[[v]], agregado$taxa_letalidade, use = "complete.obs"))
df_cor <- data.frame(variavel = names(cor_y), correlacao = round(cor_y, 4))
df_cor <- df_cor[order(-abs(df_cor$correlacao)), ]
row.names(df_cor) <- NULL
df_cor

```

```

##          variavel correlacao
## 1 prop_vacina_gripe   -0.5071
## 2   prop_hematologi    0.4554
## 3   prop_suporte_ven    0.4378
## 4         prop_uti     0.3765
## 5   prop_neurológico  -0.3412
## 6   prop_sind_down   -0.3294
## 7   prop_imunodepre    0.3264
## 8      idade_media    0.2859
## 9   prop_hepática     0.2846
## 10 prop_vacina_covid    0.2591
## 11 prop_obesidade    -0.2410
## 12 prop_pneumopatia  -0.1612
## 13      prop_renal     0.1514
## 14 prop_cardiopatias  -0.1189
## 15      prop_asma     -0.0323
## 16   prop_diabetes     0.0042

```


```

ggplot(df_cor, aes(x = correlacao, y = reorder(variavel, abs(correlacao)))) +
  geom_col(fill = "steelblue") +
  geom_vline(xintercept = 0, linetype = "dashed") +
  geom_text(aes(label = round(correlacao, 3)),
            hjust = ifelse(df_cor$correlacao >= 0, -0.15, 1.15),

```



```
size = 2.8) +
scale_x_continuous(expand = expansion(mult = c(0.08, 0.18))) +
labs(title = paste("Correlação de cada candidata com a taxa de letalidade - PR por RS,", ANO_ANALISE_1,
x = "Correlação (r) com taxa_letalidade", y = NULL) +
theme_minimal() +
theme(axis.text.y = element_text(size = 9))
```



[PREENCHER] Compare com o ranking nacional por UF em 2026 ($\text{prop_cardiopatia } 0,736 > \text{idade_media } 0,625 > \text{prop_vacina_covid } 0,604 > \text{prop_diabetes } 0,568$). O mesmo padrão aparece dentro do PR, agora por regional?

11 Passo 2 — Modelo preliminar com as 5 maiores correlações entre as candidatas clinicamente diretas (1ª rodada)

```
candidatas_principais <- intersect(
  c("idade_media", "prop_uti", "prop_cardiopatia", "prop_diabetes",
    "prop_obesidade", "prop_vacina_gripe", "prop_vacina_covid"),
  candidatas
)
ranking_principais <- df_cor[df_cor$variavel %in% candidatas_principais, ]
ranking_principais
```

```
##          variavel correlacao
## 1  prop_vacina_gripe   -0.5071
## 4      prop_uti        0.3765
## 8      idade_media     0.2859
## 10 prop_vacina_covid   0.2591
## 11   prop_obesidade   -0.2410
## 14 prop_cardiopatias  -0.1189
## 16   prop_diabetes     0.0042
```

```
top5_variaveis <- head(ranking_principais$variavel, 5)
top5_variaveis
```

```
## [1] "prop_vacina_gripe" "prop_uti"          "idade_media"
## [4] "prop_vacina_covid" "prop_obesidade"
```

```
formula_top5 <- reformulate(top5_variaveis, response = "taxa_letalidade")
formula_top5
```

```
## taxa_letalidade ~ prop_vacina_gripe + prop_uti + idade_media +
##      prop_vacina_covid + prop_obesidade
```

```
modelo_top5 <- lm(formula_top5, data = agregado)
summary(modelo_top5)
```

```
##
## Call:
## lm(formula = formula_top5, data = agregado)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.032725 -0.018035 -0.003482  0.010076  0.052347
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.070404   0.049093   1.434   0.1708
## prop_vacina_gripe -0.265673   0.112906  -2.353   0.0317 *
## prop_uti         0.028836   0.057383   0.503   0.6221
## idade_media      0.002605   0.001858   1.402   0.1799
## prop_vacina_covid -0.040723   0.148267  -0.275   0.7871
## prop_obesidade   -0.204703   0.155818  -1.314   0.2075
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02816 on 16 degrees of freedom
## Multiple R-squared:  0.5027, Adjusted R-squared:  0.3473
## F-statistic: 3.235 on 5 and 16 DF,  p-value: 0.03306
```

[PREENCHER] Com $n \approx 22$ (menor que o $n = 27$ nacional) e 5 regressores, os graus de liberdade residuais ficam mais apertados — o teste F do modelo é significativo? Os coeficientes individuais também são?

12 Passo 3 — Diagnóstico de multicolinearidade (VIF e correlação entre regressores)


```
vif(modelo_top5)
```

```
## prop_vacina_gripe      prop_utilidade      idade_media      prop_vacina_covid
##           1.364190           2.003553           5.794759           6.589880
##      prop_obesidade
##           1.656950
```

```
matriz_top5 <- cor(agregado[, top5_variaveis], use = "complete.obs")
matriz_long <- as.data.frame(as.table(matriz_top5))
names(matriz_long) <- c("var1", "var2", "correlacao")
matriz_long$abs_correlacao <- abs(matriz_long$correlacao)

ggplot(matriz_long, aes(x = var1, y = var2, fill = abs_correlacao)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(correlacao, 2)), size = 3.5) +
  scale_fill_gradientn(colors = c("forestgreen", "gold", "firebrick"),
    limits = c(0, 1), name = "|r|") +
  labs(title = paste("Correlação entre as 5 variáveis do modelo preliminar - PR por RS,", ANO_ANALISE_R),
    x = NULL, y = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 40, hjust = 1))
```

Correlação entre as 5 variáveis do modelo preliminar – PR p



Mesma regra automatizada das versões anteriores: entre cada par redundante ($|r| > 0,7$), mantém a de maior $|correlao|$ com Y e remove a outra.

```
remover_redundantes <- function(variaveis, dados, ranking_cor, limiar = 0.7) {
  repeat {
    if (length(variaveis) < 2) break
    mat <- cor(dados[, variaveis, drop = FALSE], use = "complete.obs")
    diag(mat) <- 0
    if (max(abs(mat)) <= limiar) break
    idx <- which(abs(mat) == max(abs(mat)), arr.ind = TRUE)[1, ]
    v1 <- rownames(mat)[idx[1]]; v2 <- colnames(mat)[idx[2]]
    cor_v1 <- ranking_cor$correlacao[ranking_cor$variavel == v1]
    cor_v2 <- ranking_cor$correlacao[ranking_cor$variavel == v2]
    remover <- if (abs(cor_v1) >= abs(cor_v2)) v2 else v1
    mantido <- setdiff(c(v1, v2), remover)
    message(sprintf(
      "Reespecificação: '%s' removida por redundância com '%s' (r=%.3f) - mantida a de maior |correlação| com Y",
      remover, mantido, mat[idx[1], idx[2]]
    ))
    variaveis <- setdiff(variaveis, remover)
  }
  variaveis
}
```

13 Passo 4 — Reespecificação: removendo a redundância

```
variaveis_intermediario <- remover_redundantes(top5_variaveis, agregado, df_cor, limiar = 0.7)
variaveis_intermediario
```

```
## [1] "prop_vacina_gripe" "prop_uti"          "idade_media"
## [4] "prop_obesidade"
```

```
formula_intermediario <- reformulate(variaveis_intermediario, response = "taxa_letalidade")
modelo_intermediario <- lm(formula_intermediario, data = agregado)
summary(modelo_intermediario)
```

```
##
## Call:
## lm(formula = formula_intermediario, data = agregado)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.034147 -0.016416 -0.004522  0.009686  0.056686
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.068312   0.047162   1.448   0.1657
## prop_vacina_gripe -0.266670   0.109736  -2.430   0.0265 *
## prop_uti         0.021192   0.048798   0.434   0.6695
## idade_media      0.002149   0.000813   2.644   0.0171 *
## prop_obesidade  -0.224076   0.135109  -1.658   0.1156
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02738 on 17 degrees of freedom
## Multiple R-squared:  0.5004, Adjusted R-squared:  0.3828
## F-statistic: 4.256 on 4 and 17 DF,  p-value: 0.01442
```

```
vif(modelo_intermediario)
```

```
## prop_vacina_gripe      prop_uti      idade_media      prop_obesidade
##           1.362781           1.532256           1.173415           1.317421
```

[PREENCHER] Compare com o nacional 2026 (prop_cardiopatia + idade_media + prop_obesidade). Sobrou o mesmo subconjunto dentro do PR?

14 Passo 5 — Triagem das comorbidades adicionais (2ª rodada)

```
candidatas_extra <- setdiff(candidatas, c(candidatas_principais))

resultado_triagem <- data.frame(variavel = candidatas_extra, F_parcial = NA_real_, p_valor = NA_real_)
```

```

for (v in candidatas_extra) {
  f <- as.formula(paste(
    "taxa_letalidade ~", paste(variaveis_intermediario, collapse = " + "), "+", v
  ))
  m <- lm(f, data = agregado)
  a <- anova(modelo_intermediario, m)
  resultado_triagem[resultado_triagem$variavel == v, "F_parcial"] <- a$F[2]
  resultado_triagem[resultado_triagem$variavel == v, "p_valor"] <- a$`Pr(>F)`[2]
}
resultado_triagem[order(resultado_triagem$p_valor), ]

```

```

##          variavel  F_parcial  p_valor
## 6  prop_hepatica 2.069321529 0.1695622
## 7  prop_hematologi 1.181335347 0.2931877
## 4  prop_neurologic 0.470430070 0.5026076
## 2    prop_renal 0.440987701 0.5161024
## 8  prop_sind_down 0.236553217 0.6333013
## 9  prop_suport_ven 0.222586555 0.6434459
## 3  prop_imunodepre 0.177901376 0.6787955
## 5  prop_pneumopati 0.002892582 0.9577741
## 1    prop_asma 0.001668061 0.9679272

```

Mesma regra automatizada de resolução de redundância entre candidatas aprovadas na triagem, agora medida pelo p-valor do F parcial.

```

selecionar_variavel_nova <- function(resultado, dados, limiar_p = 0.05, limiar_cor = 0.7) {
  aprovadas <- resultado$variavel[!is.na(resultado$p_valor) & resultado$p_valor < limiar_p]
  if (length(aprovadas) == 0) return(NA_character_)
  repeat {
    if (length(aprovadas) < 2) break
    mat <- cor(dados[, aprovadas, drop = FALSE], use = "complete.obs")
    diag(mat) <- 0
    if (max(abs(mat)) <= limiar_cor) break
    idx <- which(abs(mat) == max(abs(mat)), arr.ind = TRUE)[1, ]
    v1 <- rownames(mat)[idx[1]]; v2 <- colnames(mat)[idx[2]]
    p_v1 <- resultado$p_valor[resultado$variavel == v1]
    p_v2 <- resultado$p_valor[resultado$variavel == v2]
    remover <- if (p_v1 <= p_v2) v2 else v1
    mantido <- setdiff(c(v1, v2), remover)
    message(sprintf(
      "Triagem: '%s' removida por redundância com '%s' (r=%.3f) - mantida a de menor p-valor no F parcial",
      remover, mantido, mat[idx[1], idx[2]]
    ))
    aprovadas <- setdiff(aprovadas, remover)
  }
  aprovadas[which.min(resultado$p_valor[resultado$variavel %in% aprovadas])]
}

variavel_nova <- selecionar_variavel_nova(resultado_triagem, agregado)
if (is.na(variavel_nova)) {
  message("Nenhuma candidata passou na triagem (p<0,05) - modelo final = modelo intermediário do Passo 4")
} else {
  message("Variável escolhida na triagem: ", variavel_nova)
}

```

```
}
variavel_nova
```

```
## [1] NA
```

15 Passo 6 — a nova variável torna alguma do modelo intermediário desnecessária?

```
if (!is.na(variavel_nova)) {
  formula_final_teste <- reformulate(c(variaveis_intermediario, variavel_nova), response = "taxa_letalidade")
  modelo_teste <- lm(formula_final_teste, data = agregado)
  summary(modelo_teste)$coefficients
} else {
  message("Sem variável nova - nada a testar aqui; modelo final = modelo intermediário do Passo 4.")
}
```

```
decidir_variaveis_finais <- function(variaveis_base, variavel_nova, dados) {
  if (is.na(variavel_nova)) return(variaveis_base)

  variaveis_atuais <- c(variaveis_base, variavel_nova)
  modelo_atual <- lm(reformulate(variaveis_atuais, response = "taxa_letalidade"), data = dados)

  repeat {
    coefs <- summary(modelo_atual)$coefficients
    candidatas_saida <- setdiff(variaveis_atuais, variavel_nova)
    candidatas_saida <- candidatas_saida[coefs[candidatas_saida, "Pr(>|t|)"] > 0.05]
    if (length(candidatas_saida) == 0) break

    testes <- do.call(rbind, lapply(candidatas_saida, function(v) {
      vars_teste <- setdiff(variaveis_atuais, v)
      m <- lm(reformulate(vars_teste, response = "taxa_letalidade"), data = dados)
      data.frame(variavel = v, R2_ajustado = summary(m)$adj.r.squared, AIC = AIC(m))
    }))

    r2_atual <- summary(modelo_atual)$adj.r.squared
    aic_atual <- AIC(modelo_atual)
    melhor <- testes[order(-testes$R2_ajustado), ][1, ]

    if (melhor$R2_ajustado > r2_atual || melhor$AIC < aic_atual) {
      message(sprintf(
        "Passo 6: '%s' perdeu significância (p>0,05) e sua remoção melhora o ajuste (R2_aj: %.4f -> %.4f)",
        melhor$variavel, r2_atual, melhor$R2_ajustado, aic_atual, melhor$AIC
      ))
      variaveis_atuais <- setdiff(variaveis_atuais, melhor$variavel)
      modelo_atual <- lm(reformulate(variaveis_atuais, response = "taxa_letalidade"), data = dados)
    } else {
      message(sprintf(
        "Passo 6: '%s' perdeu significância individual, mas removê-la não melhora R2 ajustado nem AIC -",
        paste(candidatas_saida, collapse = ", ")
      ))
    }
  }
}
```

```

      break
    }
  }
  variaveis_atuais
}

variaveis_finais <- decidir_variaveis_finais(variaveis_intermediario, variavel_nova, agregado)
variaveis_finais

## [1] "prop_vacina_gripe" "prop_uti"          "idade_media"
## [4] "prop_obesidade"

```

15.1 Resumo do processo de seleção

Etapa	Ação	Resultado
1	Correlação com Y	[PREENCHER] variáveis no topo do ranking
2	Top 5 das candidatas principais	[PREENCHER] quais 5 entraram
3	VIF do top5	[PREENCHER] houve multicolinearidade severa?
4	Reespecificação	variaveis_intermediario (mensagens acima)
5	Triagem de comorbidades extras	variavel_nova (mensagens acima)
6	Verificação de variável desnecessária	variaveis_finais (mensagens acima)

Modelo final: definido automaticamente por `variaveis_finais`.

```

modelo <- lm(reformulate(variaveis_finais, response = "taxa_letalidade"), data = agregado)
summary(modelo)

##
## Call:
## lm(formula = reformulate(variaveis_finais, response = "taxa_letalidade"),
##     data = agregado)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.034147 -0.016416 -0.004522  0.009686  0.056686
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.068312   0.047162   1.448   0.1657
## prop_vacina_gripe -0.266670   0.109736  -2.430   0.0265 *
## prop_uti         0.021192   0.048798   0.434   0.6695
## idade_media      0.002149   0.000813   2.644   0.0171 *
## prop_obesidade  -0.224076   0.135109  -1.658   0.1156
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```



```
##
## Residual standard error: 0.02738 on 17 degrees of freedom
## Multiple R-squared: 0.5004, Adjusted R-squared: 0.3828
## F-statistic: 4.256 on 4 and 17 DF, p-value: 0.01442
```

16 Ajuste e Diagnóstico do Modelo Final

```
anova(modelo)
```

```
## Analysis of Variance Table
##
## Response: taxa_letalidade
##          Df      Sum Sq   Mean Sq F value    Pr(>F)
## prop_vacina_gripe 1 0.0065594 0.0065594   8.7500 0.008807 **
## prop_utili         1 0.0004922 0.0004922   0.6566 0.428948
## idade_media        1 0.0036485 0.0036485   4.8670 0.041422 *
## prop_obesidade     1 0.0020620 0.0020620   2.7506 0.115554
## Residuals         17 0.0127440 0.0007496
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
confint(modelo, level = 0.95)
```

```
##              2.5 %      97.5 %
## (Intercept) -0.031190116 0.167815080
## prop_vacina_gripe -0.498192702 -0.035146992
## prop_utili      -0.081762608 0.124147193
## idade_media      0.000434279 0.003864676
## prop_obesidade   -0.509130314 0.060978425
```

```
vif(modelo)
```

```
## prop_vacina_gripe      prop_utili      idade_media      prop_obesidade
##           1.362781           1.532256           1.173415           1.317421
```

```
X_final <- agregado[, variaveis_finais, drop = FALSE]
autovalores_final <- eigen(cor(X_final, use = "complete.obs"))$values
kappa_final <- max(autovalores_final) / autovalores_final
data.frame(autovalor = round(autovalores_final, 4),
            indice_condicao = round(kappa_final, 2))
```


```
## autovalor indice_condicao
## 1      1.8568           1.00
## 2      1.0547           1.76
## 3      0.6749           2.75
## 4      0.4137           4.49
```

16.1 Comparação com o modelo reduzido (teste F parcial da última variável adicionada)

```
if (!is.na(variavel_nova) && variavel_nova %in% variaveis_finais && length(variaveis_finais) > 1) {  
  variaveis_reduzido <- setdiff(variaveis_finais, variavel_nova)  
  modelo_reduzido <- lm(reformulate(variaveis_reduzido, response = "taxa_letalidade"), data = agregado)  
  
  anova(modelo_reduzido, modelo)  
  
  data.frame(  
    modelo = c(paste(variaveis_reduzido, collapse = " + "), paste(variaveis_finais, collapse = " + ")),  
    R2_ajustado = c(summary(modelo_reduzido)$adj.r.squared, summary(modelo)$adj.r.squared),  
    AIC = c(AIC(modelo_reduzido), AIC(modelo))  
  )  
} else {  
  message(  
    "Não há teste F parcial a fazer aqui: nenhuma variável da triagem (Passo 5) ",  
    "entrou no modelo final, ou ela foi removida no Passo 6."  
  )  
}
```

16.2 Gráficos de diagnóstico padrão dos resíduos

```
par(mfrow = c(2, 2))  
plot(modelo)
```



```
par(mfrow = c(1, 1))
```

16.3 Resíduos studentizados internos e R-student

```
residuos_padronizados <- rstandard(modelo)
r_student <- rstudent(modelo)

tabela_residuos <- data.frame(
  regional = agregado$regional_nome,
  residuo_padronizado = round(residuos_padronizados, 2),
  r_student = round(r_student, 2)
)
tabela_residuos[order(-abs(tabela_residuos$r_student)), ]
```

	regional	residuo_padronizado	r_student
## 22	9ª RS - Foz do Iguaçu	2.15	2.44
## 11	19ª RS - Jacarezinho	1.95	2.15

## 5	13ª RS - Cianorte	1.80	1.94
## 17	4ª RS - Irati	-1.54	-1.61
## 14	21ª RS - Telêmaco Borba	-1.25	-1.27
## 21	8ª RS - Francisco Beltrão	-1.04	-1.04
## 8	16ª RS - Apucarana	-0.97	-0.97
## 15	22ª RS - Ivaiporã	-0.94	-0.94
## 7	15ª RS - Maringá	0.80	0.79
## 1	1ª RS - Paranaguá	-0.74	-0.73
## 19	6ª RS - União da Vitória	-0.67	-0.66
## 9	17ª RS - Londrina	-0.54	-0.53
## 4	12ª RS - Umuarama	0.50	0.49
## 13	20ª RS - Toledo	-0.44	-0.43
## 6	14ª RS - Paranavaí	0.43	0.42
## 3	11ª RS - Campo Mourão	0.41	0.40
## 12	2ª RS - Curitiba (Metropolitana)	0.34	0.33
## 18	5ª RS - Guarapuava	-0.33	-0.32
## 16	3ª RS - Ponta Grossa	-0.23	-0.22
## 2	10ª RS - Cascavel	0.20	0.20
## 10	18ª RS - Cornélio Procópio	-0.18	-0.18
## 20	7ª RS - Pato Branco	0.12	0.12


```
# regra prática: |r_student| > 2 sinaliza possível outlier
```

16.4 Resíduos vs. cada regressor

```
agregado$residuo <- residuos_padronizados
agregado$indice <- 1:nrow(agregado)
fora_intervalo <- subset(agregado, abs(residuo) > 1)

graficos_residuo <- lapply(variaveis_finais, function(v) {
  ggplot(agregado, aes(x = .data[[v]], y = residuo)) +
    geom_point() + geom_hline(yintercept = 0, linetype = "dashed") +
    geom_hline(yintercept = c(-1, 1), linetype = "dotted", color = "gray50") +
    geom_text(data = fora_intervalo, aes(label = indice), vjust = -0.8, size = 3, color = "red") +
    labs(x = v, y = "Resíduo padronizado") + theme_minimal()
})

do.call(grid.arrange, c(graficos_residuo, ncol = length(graficos_residuo)))
```



16.5 Estatística PRESS

```
press_residuos <- residuals(modelo) / (1 - lm.influence(modelo)$hat)
PRESS <- sum(press_residuos^2)
SQE <- sum(residuals(modelo)^2)

data.frame(SQE = round(SQE, 5), PRESS = round(PRESS, 5),
           razao_PRESS_SQE = round(PRESS / SQE, 2))
```

```
##          SQE    PRESS razao_PRESS_SQE
## 1 0.01274 0.02097           1.65
```

16.6 Alavancagem e Distância de Cook

```
p <- length(coef(modelo))
n <- nrow(agregado)
limite_hat <- 2 * p / n

hat_values <- lm.influence(modelo)$hat
cooks_d <- cooks.distance(modelo)

tabela_influencia <- data.frame(
  regional = agregado$regional_nome,
  hat = round(hat_values, 3),
  acima_do_limite = hat_values > limite_hat,
  Cooks_D = round(cooks_d, 3)
)
tabela_influencia[order(-tabela_influencia$Cooks_D), ]
```


```
##          regional    hat acima_do_limite Cooks_D
## 11          19ª RS - Jacarezinho 0.323         FALSE  0.363
## 17           4ª RS - Irati 0.341         FALSE  0.244
## 5          13ª RS - Cianorte 0.193         FALSE  0.156
```

```
## 14      21ª RS - Telêmaco Borba 0.262      FALSE  0.111
## 15      22ª RS - Ivaiporã 0.373          FALSE  0.106
## 22      9ª RS - Foz do Iguaçu 0.071        FALSE  0.070
## 1       1ª RS - Paranaguá 0.345           FALSE  0.058
## 6       14ª RS - Paranavaí 0.449          FALSE  0.030
## 7       15ª RS - Maringá 0.176            FALSE  0.027
## 19      6ª RS - União da Vitória 0.198     FALSE  0.022
## 21      8ª RS - Francisco Beltrão 0.087    FALSE  0.020
## 8       16ª RS - Apucarana 0.087          FALSE  0.018
## 4       12ª RS - Umuarama 0.221           FALSE  0.014
## 3       11ª RS - Campo Mourão 0.211        FALSE  0.009
## 10      18ª RS - Cornélio Procópio 0.591    TRUE   0.009
## 9       17ª RS - Londrina 0.102           FALSE  0.007
## 13      20ª RS - Toledo 0.094             FALSE  0.004
## 18      5ª RS - Guarapuava 0.148           FALSE  0.004
## 12 2ª RS - Curitiba (Metropolitana) 0.087  FALSE  0.002
## 20      7ª RS - Pato Branco 0.392         FALSE  0.002
## 2       10ª RS - Cascavel 0.147           FALSE  0.001
## 16      3ª RS - Ponta Grossa 0.102        FALSE  0.001
```

```
limite_hat
```

```
## [1] 0.4545455
```

```
plot(modelo, which = 5, id.n = nrow(agregado))
```



17 Equação do Modelo Final

```
coefs <- coef(modelo)
sinal <- function(x) if (x >= 0) "+" else "-"

termos <- paste(sprintf("%s %.4f*%s", sapply(names(coefs)[-1], sinal), abs(coefs[-1]), names(coefs)[-1]),
cat(sprintf("taxa_letalidade = %.4f %s\n", coefs["(Intercept)"], termos))

## taxa_letalidade = 0.0683 + 0.2667*prop_vacina_gripe + 0.0212*prop_uti + 0.0021*idade_media + 0.2241*

cat(sprintf("R2 = %.4f | R2_ajustado = %.4f\n",
summary(modelo)$r.squared, summary(modelo)$adj.r.squared))

## R2 = 0.5004 | R2_ajustado = 0.3828
```

18 Comparação com a análise nacional (UF, 2026) e com 2024

[PREENCHER] — depois de rodar tudo, resuma aqui:

- O modelo final por Regional de Saúde do PR usa as mesmas variáveis que o nacional 2026 (prop_cardiopatia + idade_media + prop_pneumopati) ou variáveis diferentes?
- idade_media se repetiu nos três níveis (UF-2024, UF-2026, RS-PR-2026)?
- R^2 ajustado é maior, menor ou parecido com o nacional 2026 (0,767)?
- Alguma regional específica se destaca como ponto de alta influência (olhar Distância de Cook acima) — e isso tem explicação plausível (regional pequena, poucos casos, perfil de rede hospitalar)?
- Vale lembrar: com $n \approx 22$ e agregação intra-estadual, a amostra é ainda menor e mais sensível a município por município do que a análise por UF — leia os resultados com essa reserva extra.